עיבוד שפה טבעית – הנחיות לפרויקט סיום

מטלת הסיום בקורס עיבוד שפה טבעית היא פרויקט, בקורס לא מתקיים מבחן. מטרת המסמך הקצר הזה היא לסכם את מטרת הפרויקט, אופן הגשתו והדרך בה ניתן הציון. אנא קראו אותו היטב לפני תחילת העבודה.

מטרת והיקף הפרויקט:

מטרת הפרויקט היא התמודדות עם בעיית Action Prediction בסיטואציה שפתית. כל קבוצה בת 1-2 סטודנטים תתמודד עם מטלה הכוללת יישום החומר שנלמד בכיתה, הרצת ניסויים וניתוח התוצאות בהיקף של מחקר קטן והצגת תרומה אלגוריתמית חדשנית (קטנה) לבעיה.

בפרויקט, תעבדו עם קוד ודאטה <u>מהמאמר שעילם הציג בהרצאה 10</u>. מטרת המחקר היא לחזות פעולות בינאריות של שחקנים בסיטואציה של משחק חוזר, בהתבסס על סיגנל שפתי שהוצג להם. בפרויקט, אתם תציעו ותממשו מספר רעיונות, ותבחנו את התוצאות שלהם בשיפור החיזוי במשימה המוצגת במאמר.

<u>מבנה הפרויקט:</u>

הפרויקט מחולק לשלושה חלקים:

- בחירת נושא המחקר, כתיבת אבסטרקט (תקציר) המחקר, והגדרת תוכנית עבודה עצמית(20%) להגשה ב-4.4.
 - הכותרת צריכה לתאר באופן ברור את נושא המחקר שלכם.
- האבסטרקט צריך להכיל עד 250 מילים, ועליו לתאר את הבעיה שזיהיתם, המצב כמחקרי הקיים והכיוונים שאתם מתכננים לבדוק במהלך הפרויקט לפתרון הבעיה.
- תוכנית העבודה צריכה להגדיר משימות לביצוע במסגרת הפרויקט, תכנון לוח זמנים לעבודה על הפרויקט ולהרצות של הניסויים. התוכנית צריכה להתחשב בזמני ההרצה של הקוד וכן בדד ליין שלכם. יש לתאר את הניסויים אותם אתם מתכננים להריץ, לחשב את מספר הניסויים המינימלי שתריצו ולחשב לכמה ריצה אתם נדרשים.
 - כתיבת מאמר קצר באורך 4 עמודי ACL המתאר את העבודה שלכם (60%) להגשה ב-10.6.
- החלק הבסיסי של המטלה. המאמר צריך לתאר בקצרה ובצורה בהירה את העבודה
 ישלכם
 - Intro, Related Work, Model, Data, המאמר צריך להכיל את הפרקים: Experiments and Results
 - ההגשה צריכה להיות באנגלית בלבד.
 - הגשת קוד מסודר המאפשר שחזור מלא של התוצאות (20%) להגשה ב-10.6.
- אתם נדרשים להגיש קוד ברור ונקי המאפשר שחזור מהיר של כל התוצאות במאמר.○
 - יש להעלות את הקוד שלכם לgithub, ל-repository ס יש להעלות את הקוד שלכם
 - יש לתת גישת צפייה למשתמשים הבאים: כדי שנוכל לבדוק את הקוד שלכם, יש לתת גישת צפייה למשתמשים הבאים: eilamshapira, itay-nakash, ilanit1997

כיווני מחקר מרכזיים אפשריים:

- שיפור רכיבי הסימולציה: המאמר מציג שיטת סימולציה בסיסית שבה השחקן הסימולטיבי משחק לפי אחת משלוש אפשרויות בסיסיות: מבוסס שפה, מבוסס היסטוריה או רנדומי. ככל שהמשחק מול הבוט מתקדם, השחקן משחק פחות אחת אחת מהאפשרויות הבסיסיות ויותר באפשרות רביעית ("אורקל"), בה הוא יבצע בכל מקרה את הפעולה הנכונה. בכיוון מחקר זה, תנסו לשפר את ביצועי המודל בעזרת סימולציה מורכבת יותר שתציעו.
 - 2. ארכיטקטורה חדשה לשיפור הביצועים: המאמר מראה כי LSTM עדיפה על 2 ביצוע החיזוי אולם אנחנו מאמינים כי LSTM לא הארכיטקטורה האידיאלית למידול לצורך ביצוע החיזוי אולם אנחנו מאמינים הענסו למידול משימת החיזוי.
- 3. <u>כיוון מחקר עצמאי לפרויקט המשך:</u> אותו תציעו ותיישמו בעצמכם. יש לאשר כיוון זה עם סגל הקורס עד לתאריך 28.3.

כיווני מחקר משניים:

כיווני מחקר אלו לא עומדים כפרויקט בפני עצמו, אולם הם עשויים לסייע לכם להגיע לתוצאות טובות יותר בפרויקט שלכם. ההגשות המצטיינות בכיווני המחקר המשניים יזכו בבונוס לציון.

- 1. ייצוג טוב יותר לקלט השפתי/התנהגותי
 - 2. שיפור ביצועים (מבחינת זמן הריצה)

הכנת הפרויקט והגשתו: הפרויקט יוכן במספר שלבים, כדלקמן:

- בשבועיים האחרונים של הקורס יוקדשו 4 משעות התרגולים ומשעות הקבלה למפגשים עם עילם לשאלות על המחקר המקורי ולשיח על רעיונות אפשריים לפרויקט. המטרה של המפגשים האלו היא לעזור לכם לגבש רעיונות לפרויקט. כדאי להגיע למפגשים האלו לאחר היכרות עם המאמר המקורי והקוד, ולאחר מחשבה על כיווני המחקר שמעניינים אתכם.
- על כל קבוצה להגיש הצעת מחקר הכוללת את הכותרת והאבסטרקט שלכם. האבסטרקט צריך להכיל את האלגוריתם שימומש והדאטה שעליו יבוצעו הניסויים. ההצעה תהיה באורך 250 מילים באנגלית. בנוסף, יש להגיש תוכנית עבודה. תוכנית העבודה תגדיר משימות לביצוע במסגרת הפרויקט, תכנון לוח זמנים לעבודה על הפרויקט ולהרצות של הניסויים. התוכנית צריכה להתחשב בזמני ההרצה של הקוד וכן בדד ליין שלכם. יש לתאר את הניסויים אותם אתם מתכננים להריץ, לחשב את מספר הניסויים המינימלי שתריצו ולחשב לכמה ריצה אתם נדרשים.
 - תאריך אחרון להגשת ההצעה ותוכנית העבודה הוא ה-4.4 כל יום איחור לאחר מכן יגרע שתי נקודות מהציון הסופי בפרויקט.
- הגשת מאמר קצר: על כל קבוצה להגיש מאמר של עד ארבעה עמודים באנגלית. המאמר יסכם את כל חלקי הפרויקט (הספרות הרלוונטית, המודל, הדאטה והתוצאות) על כל ההיבטים שלהם. חשוב לחלק את המאמר כך שיכלול בין השאר תיאור של האלגוריתמים, הניסויים, הניתוחים וכל מה שנעשה בפרויקט. כל איחור בהגשה של הדו"ח יוריד שתי נקודות מציון הקורס.

- הגשת הקוד: על כל קבוצה להגיש את הקוד שנכתב לצורך מימוש האלגוריתמים, הניסויים והניתוחים. אתם נדרשים להגיש קוד ברור ונקי המאפשר שחזור מהיר של כל התוצאות במאמר.
- 1. את עיקר הקוד יש להגיש באמצעות github: צרו repository פרטי ותנו הרשאות פוlamshapira, itay-nakash, ilanit1997.
 - 2. יש להגיש את קבצי קוד (מסוג py או py) המנתחים את התוצאות שלכם, באמצעות תיקייה בשם Notebooks_YOUR_UID.
- 3. להגשה במודל העלו את הקובץ clone_and_init_YOUR_UID.sh אשר באמצעותו נוכל להוריד ולהריץ את קבצי הקוד שלכם בקלות, ובנוסף קובץ pdf של ובוסף המאמר הקצר בשם ID1_ID2_YOUR_UID.pdf.

בכל קבצי ההגשה ושמותיהם, השתמשו בשם המשתמש שלכם ב-github בתור YOUR_UID.

<u>ציון הפרויקט:</u>

10% תוכנית עבודה

10% רעיונות/חדשנות

10% איכות וחדשנות הרעיונות והשינויים, וכן מקוריותם (בהשוואה לפתרונות שהוצעו על ידי קבוצות אחרות)

<u>60% מאמר קצר</u>

5% איכות התקציר

10% מבוא

10% סקירת ספרות

(ביצוע הרעיון) אור הדאטה והמודל (ביצוע הרעיון)

10% ניתוח התוצאות

10% איכות התוצאות

נציין כי איכות הכתיבה תקבל משקל לא מבוטל מציון המאמר.

השימוש ב-GPT מותר כעזר לכתיבה, ולא כתחליף לחשיבה ולעריכה שלכם. אסור שיראה כאילו GPT כתב את הטקסט שלכם.

20% קוד

10% איכות הקוד

10% קלות שחזור התוצאות

<u>הקבצים</u>

התיקייה הראשית

או שורת הפקודה) StrategyTransfer.py - הקובץ המרכזי. מקבל פרמטרים (באמצעות <u>wandb</u> או שורת הפקודה) ויוצר את סביבת האימון לפי הארכיטקטורה שקיבל.

cell state - ארכיטקטורה מבוססת LSTM אשר מאפשרת שמירה של ה-SpecialLSTM.py לשימוש עתידי.

consts.py - רשימת משתנים קבועים וערכיהם.¹

<u>אטה של הפרויקט - /data</u>

.oo - data/game reviews - סט המלונות מהמשחק והביקורות שלהם.

לדוגמא: הקובץ data/game_reviews/34.csv מכיל את שבע הביקורות מהן סוכן הנסיעות יכול לבחור את הביקורת אותה יציג עבור מלון מספר 34.

- ייצוג ה-EFs של כל הביקורות. - data/EFs_by_GPT35.csv

data/BERT_PCA_36.csv - ייצוג הביקורות על ידי BERT לאחר הטלה למימד 36 באמצעות PCA.

data/GPT4_PCA_36.csv - ייצוג הביקורות על ידי GPT4 Embeddings לאחר הטלה למימד 36 באמצעות PCA.

o - data/games_clean_X.csv - סט הפעולות של השחקנים מסט המבחן (מכיל נתונים של 210 השחקנים ששיחקו מול האסטרטגיות (E_A).

o - data/games_clean_Y.csv - סט הפעולות של השחקנים מסט המבחן (מכיל נתונים של 35 השחקנים ששיחקו מול האסטרטגיות (E_B).

- data/baseline_proba2go.txt - ההסתברות ללכת למלון בהנתן ביקורת, לפי האסטרטגיה 'Language-based' מהמאמר.

environments - תיקייה המכיל את האריכטקטורות השונות שכבר מומשו לצורך המחקר

environments/environment.py - קובץ אימון המודל. כולל את סביבת האימון ולולאת האימון.

environments/LSTM_env.py - מודל מסוג LSTM. משתמש בארכיטקטורה SpecialLSTM. המודל המוצג במאמר בתור LSTM.

environments/transformer_env.py - מודל מסוג Transformer - מודל מסוג - environments/transformer - env.py

תיקייה המכילה קבצי עזר לסימולציה המוצגת במאמר /Simulation

Simulation/strategies_code.py - קובץ המכיל את פונקציות המבצעות את ההחלטות של סוכני הנסיעות הנמצאים במרחב האסטרטגיות.

_

בעבר. בעברו שתוכלו לשנות ולערוך גם ערכים שהיו קבועים בעבר. 1

Simulation/dm_strategies.py - קובץ המכיל את הפונקציות המבצעות את ההחלטות של כל האסטרטגיות איתן ה-DM יכול לפעול.

utils - תיקיית המכילה קבצי עזר שונים

utils/datasets.py - מכילה את המימוש המלא עבור מחלקות ה-Dataset - מכילה את המימוש המלא עבור מחלקות ה-OnlineSimulationDataSet - בפרויקט: OfflineDataSet לעבודה עם csv של נתונים, ו-Trav של נתונים, ו-Trav מימולציה תוך כדי האימון.

- utils/basic_nature_options.py - utils/basic_nature options.py - שימה המכילה שונות להתפלגות temperament vector- 2

utils/samplers.py - מימוש לטיפוס sampler שדואג לכך שבכל אפוק עבור השחקן x הדאטה של - utils/samplers.py - מימוש לטיפוס ו 'i<j. משחק ה-i יכנס למודל לפני הדאטה של המשחק ה-i.

utils/usersvectors.py - מחלקה השומרת בזיכרון hidden vectors של שחקנים ומאפשרת גישה אליהם.

- utils/functions.py - פונקציות עזר שונות.

<u>איך להריץ?</u>

להורדת קבצי הקוד והדאטה, יש לבצע clone ל-git repository הבא:

https://github.com/eilamshapira/HumanChoicePrediction

ולפעול לפי הוראות ההתקנה.

קובץ ההרצה הראשי הוא StrategyTransfer.py, <u>ולא main.py</u>. הפרמטרים הדיפולטיים להרצה מופיעים בקובץ זה.

ניתן להריץ את המודל באמצעות הקוד הבא:

python StrategyTransfer.py

כדי לשנות את הפרמטרים של המודל, ניתן להעביר אותם בשורת הפקודה:

python StrategyTransfer.py -- ENV LEARNING RATE=0.002

יריץ את קוד האימון כאשר הפרמטר ENV_LEARNING_RATE שווה ל-2e-3 (ולא עם הערך הדיפולטי שלו, 3-1e-3, המופיע בשורה 24 בקובץ StrategyTransfer.py).

כדי להריץ ניסוי הבודק מספר פרמטרים גדול, אנחנו ממליצים לעבוד עם wandb sweeps.

[.]basic nature ההתפלגות באמצעות ההרשימה הזו באמצעות מהרשימה 2

קוד היוצר sweep לניסוי לדוגמה בו אנו בודקים את ההשפעה של סוג הוקטורים המייצגים את הביקורות (EFs/GPT4/BERT) עבור גדלי סימולציה שונים מופיע בקובץ RunningScripts/final sweep demo.py.

<u>דוגמא למאמרים קצרים בפורמט של ארגון ה-ACL (הארגון האקדמי המרכז את התחום של עיבוד שפה טבעית):</u>

- https://arxiv.org/pdf/2106.04484.pdf •
- https://aclanthology.org/2021.emnlp-main.171.pdf •
- https://aclanthology.org/2021.emnlp-main.256.pdf •
- https://aclanthology.org/2021.emnlp-main.739.pdf •
- https://aclanthology.org/2021.emnlp-main.631.pdf
 - <u>רשימת מאמרים שהתקבלו לכנס EMNLP</u>

:ACL פורמט

https://github.com/acl-org/acl-style-files/tree/master